

基于SVD与RSVD方法的图像压缩

Xiaoma

2023 年 3 月 26 日

摘要

在现实世界中，我们经常需要对图像进行传输或存储，图像的大小与传输和存储的成本密切相关，所以我们需要在尽可能保证图像质量的前提下，采用相应的技术，对图像进行压缩。第一种方法是基于SVD对图像进行压缩，可以使图像在保证部分重要特征的同时采用更小规模的数据来表示，另外一种为基于Randomized-SVD方法的图像压缩，该方法在保证精度与前者相同的情况下，大幅提高了压缩速度。

一、前言

现实世界中每天都会产生大量的数据，如文本、音频、视频、图像等。通过图片来传递信息对于我们来说是非常普遍的。智能手机和智能设备领域的革命使使用者能更方便的使用数据。^[3]就存储成本而言，存储未压缩的图像的成本是十分高昂的，传输未压缩的图像往往也要占用更大的带宽，所以对图像传输与存储前的压缩是一个非常重要的问题，且在压缩过程中，应在压缩率与特征保留之间进行权衡。

二、相关工作

1. 实现基于SVD方法的图像压缩算法
2. 实现基于Randomized-SVD方法的图像压缩算法
3. 分别对两种方法进行比较
4. 启发式分析

三、问题分析

3.1 分析

由于对本问题的分析应尽量接近显示生活，故我们将对彩色图像进行压缩。彩色图像由RGB三种基本颜色构成，若图像的尺寸为 $m * n$ ，则在计算机中以 $m * n * 3$ 的矩阵形式存储，所以在压缩过程中应分别压缩三个矩阵。

四、建模的假设

4.2 假设1

需要进行压缩的图片不考虑无损压缩方式（如哈夫曼编码）。

4.3 假设2

需要进行压缩的图片要保留一定的特征。

五、符号说明

表 1: 符号说明

符号	说明
M	原输入矩阵
U	M 的左奇异向量
Σ	对角线为 M 奇异值的实对角矩阵
V^*	M 的右奇异向量
A_R	M 的 R 通道压缩矩阵
Q	M 的近似基
Ω	随机向量矩阵

六、数学模型建立

奇异值分解

奇异值分解是线性代数中一种重要的矩阵分解，现在被广泛应用于信号处理、机器学习等领域。假设 M 是一个 $m * n$ 阶矩阵，其中的元素全部属于域 K ，则存在一个分解使得 $\mathbf{M} = \mathbf{U}\Sigma\mathbf{V}^*$ ，其中 \mathbf{U} 是 $m * m$ 阶酉矩阵， Σ 是 $m * n$ 阶非负实对角矩阵， \mathbf{V}^* 是 $n * n$ 阶酉矩阵，这样的分解就成为奇异值分解。 Σ 对角线上的元素即为 \mathbf{M} 的奇异值。

基于SVD的图像压缩

通过SVD方法可以更多的利用图像的冗余特征，将这部分区域消除后，可以降低图像所需的存储空间并尽可能保证图像完整性。即SVD方法可以使用一个低维矩阵去近似高维矩阵，将特征值按照降序排

列，则再图像压缩过程中，将排在后面的特征丢弃，保留排在前面的特征，以将信息损失最小化。若假设压缩后的图像要保留 k 个特征，则最终得到的图像矩阵为

$$A_R = \mu_1 u_1 v_1^T + \mu_2 u_2 v_2^T + \dots + \mu_k u_k v_k^T$$

$$A_G = \mu_1 u_1 v_1^T + \mu_2 u_2 v_2^T + \dots + \mu_k u_k v_k^T$$

$$A_B = \mu_1 u_1 v_1^T + \mu_2 u_2 v_2^T + \dots + \mu_k u_k v_k^T$$

$$A = [A_R, A_G, A_B]$$

基于Randomized-SVD的图像压缩

通过一种随机化思想，使用随机投影来识别子空间，以获得矩阵的主要特征。首先从原式矩阵 M 的列空间中获得一个近似基 Q 且满足 $M \approx Q Q^* M$ ，其中 Q 的列向量是正交的，通过设置需要获得的奇异值个数 k 以及过采样参数 p ，构建一个由 $k + p$ 个 n 维的随机列向量组成的矩阵 Ω ，要求 $(k + p) \leq \min(m, n)$ ，每一个列向量中的值均采样自标准正态分布，因此，这些采样的列向量线性独立，进行矩阵乘积运算 $Y = M\Omega$ ，由于向量集合 Y 也是线性独立的，则 Y 为矩阵 M 的列向量空间。通过求取向量集合 Y 的正交基，从而得到 M 的近似基 Q 。

然后构建低维矩阵 B ，满足 $B = Q^* M$ ，并计算低维矩阵 B 的SVD分解，使得 $B = \bar{U} \Sigma V^*$ ， B 是一个 $k + p$ 行 n 列的矩阵，相比初始矩阵 $M(mn)$ ， B 的行数非常小，更易于进行SVD分解。矩阵 M 实际的左奇异向量 U 为 $U = Q \bar{U}$ 。

该算法的步骤如下

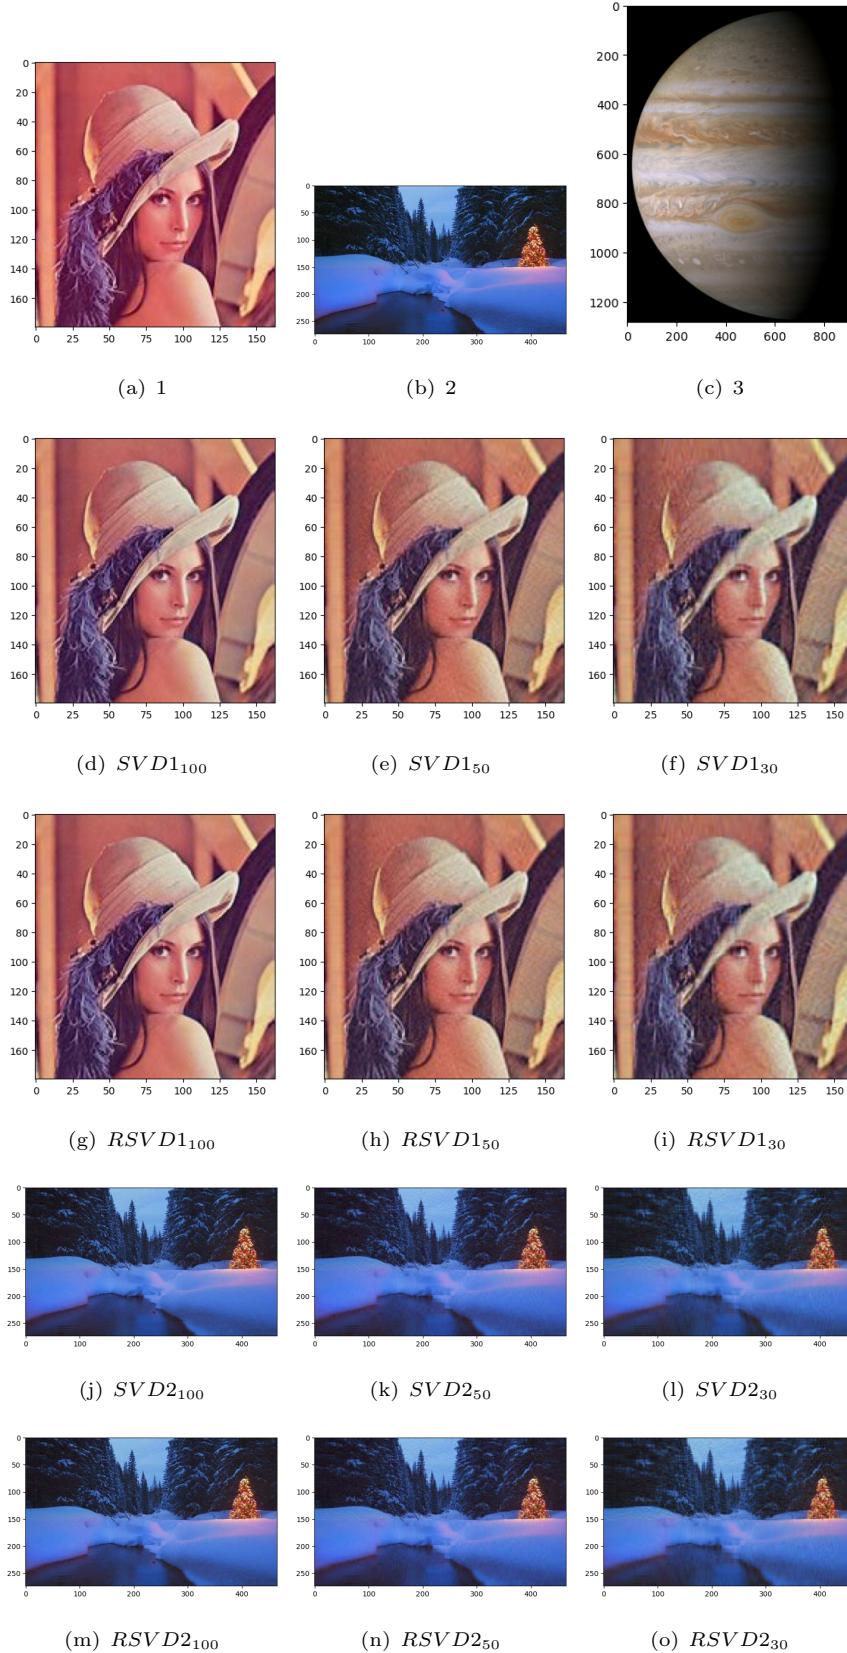
Algorithm 1 basic rSVD [1]

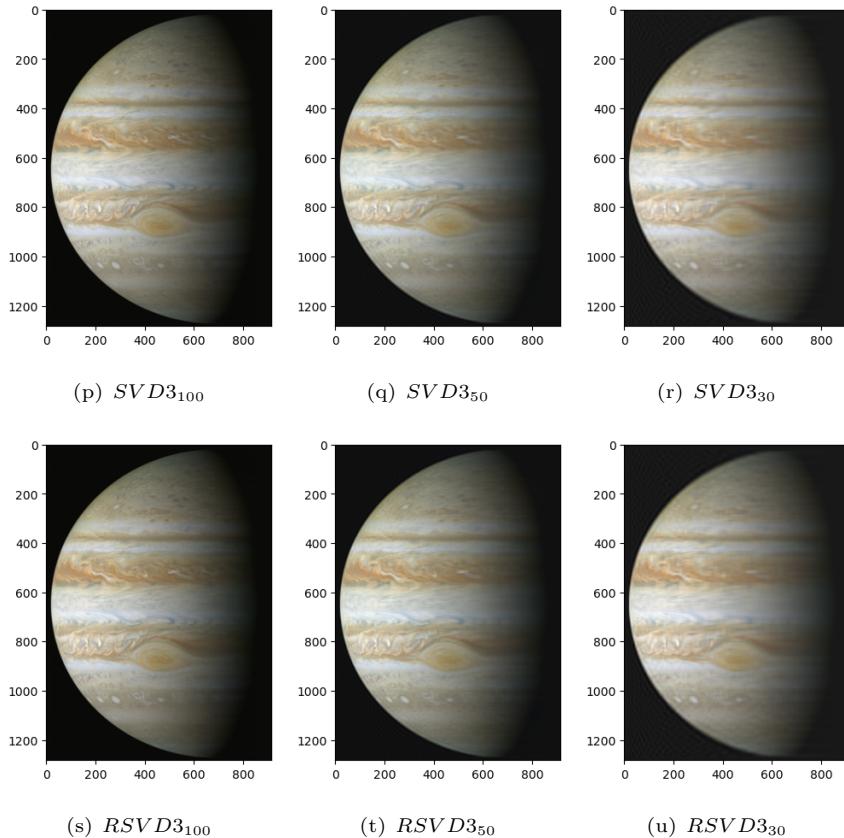
Input: $A \in \mathbb{R}^{m \times n}$, rank parameter k , power parameter p
Output: $U \in \mathbb{R}^{m \times k}$, $S \in \mathbb{R}^{k \times k}$, $V \in \mathbb{R}^{n \times k}$

- 1: $\Omega = \text{randn}(n, k + s)$
- 2: $Q = \text{orth}(A\Omega)$
- 3: for $i = 1, 2, \dots, p$ do
- 4: $G = \text{orth}(A^T Q)$
- 5: $Q = \text{orth}(AG)$
- 6: end for
- 7: $B = Q^T A$
- 8: $[U, S, V] = \text{svd}(B)$
- 9: $U = QU$
- 10: $U = U(:, 1:k)$, $S = S(1:k, 1:k)$, $V = V(:, 1:k)$

七、结果（与对比）

将SVD方法压缩的图像与RSVD方法压缩的图像进行对比





八、结论

基于Randomized-SVD方法的图像压缩在保证图像质量相同的情况下，压缩速度较SVD方法相比快6-7倍。

九、问题

两种算法都需要手动调整特征数参数 k ，在处理大规模数据时手动调整参数时间成本过高，设定固定参数又不能保证所有图像的质量。

此外，对于整个图像来说，全局SVD可以得到全局的奇异值的对应排列，但在全局相对不重要的特征可能在图像的某个部分是十分重要的，因此全局SVD会造成图像局部信息丢失的问题。将图像中的数据用一个与其无关的称之为shuf的排列 S 打乱，然后使用SVD分解得到的矩阵 $X = S(M)$ ，假设 $X_r = \mathbf{U}_r \Sigma_r \mathbf{V}_r^*$ 表示对 X 获得的近似值。实验发现，对于相同的 r 值，图像 $S^{-1}(X_r)$ 是一个比 M_r 更好的近似值。
[2]

参考文献

- [1] Xu Feng, Wenjian Yu, and Yaohang Li. Faster matrix completion using randomized svd. In *2018 IEEE 30th International Conference on Tools with Artificial Intelligence (ICTAI)*, pages 608–615, 2018.
- [2] Abhiram Ranade, Srikanth S Mahabalaraao, and Satyen Kale. A variation on svd based image compression. *Image and Vision computing*, 25(6):771–777, 2007.
- [3] H R Swathi, Shah Sohini, Surbhi, and G Gopichand. Image compression using singular value decomposition. *IOP Conference Series: Materials Science and Engineering*, 263(4):042082, nov 2017.